

Lista 08 de FECD

Exercício 8

- A quantidade D^2 tem um valor típico (ou valor esperado): $E(D^2) = ??$.
- D^2 possui um afastamento típico de seu valor esperado, seu DP. O desvio-padrão de D^2 é: $\text{raiz}(V(D^2)) = ??$.
- Mais que isto, não somente estes dois resumos da distribuição de D^2 são conhecidos mas a própria distribuição de D^2 é conhecida. $D^2 \sim ??$.
- Fixando uma constante c qualquer, o conjunto de pontos $x \in \mathbb{R}^p$ que satisfazem $D^2 = c$ formam um elipsoide em p dimensões. Isto é, os pontos x que estão a uma distância D^2 igual a c do seu perfil esperado formam um elipsoide. Quais são os eixos deste elipsoide e os seus tamanhos relativos?
- É possível mostrar que, com probabilidade $1 - \alpha$, o vetor aleatório X deve cair dentro da elipse $D^2 = c$ onde $c = \chi^2_{p(\alpha)}$ e o quantil $(1 - \alpha)100\%$ de uma distribuição qui-quadrado com p graus de liberdade onde p é a dimensão do vetor X . No caso particular de um vetor bidimensional, o valor de c associado com a probabilidade $1 - \alpha = 0.95$ é igual a $c = 9.21$. Assim, se $X = (X_1, X_2)$ estiver fora dessa elipse (isto é, se $D^2 > 9.21$), o ponto pode ser considerado um tanto anômalo ou extremo. O arquivo `stiffness.txt` contém quatro tipos de medições da rigidez de pranchas de madeira. A primeira é obtida aplicando-se uma onda de choque através da prancha, a segunda aplicando-se uma vibração a prancha e as outras duas são obtidas por meio de testes estáticos. Assuma que cada uma das 4 medições em uma prancha são instâncias de um vetor $N_4(\mu, \Sigma)$. Estime o vetor μ e a matriz 4×4 Σ usando os dados da amostra. A seguir, usando estes valores estimados como se fossem os verdadeiros valores de μ e Σ , calcule o valor de D^2 para cada ponto da amostra. Quais pontos parecem extremos? Olhando as variáveis INDIVIDUALMENTE ou em pares através de scatterplots seria possível detectar estes pontos extremos? Faça scatterplot dos dados para entender sua resposta.

Resposta de todas as perguntas acima:


É possível deduzir que, se $X \sim N_p(\mu, \Sigma)$, então D^2 segue uma distribuição qui-quadrado com p graus de liberdade. Isto permite obter $E(D^2) = p$ e também $V(D^2) = 2p$. Os eixos do elipsoide estão na direção dos autovetores da matriz Σ e com tamanhos proporcionais à raiz quadrada de seus autovalores.

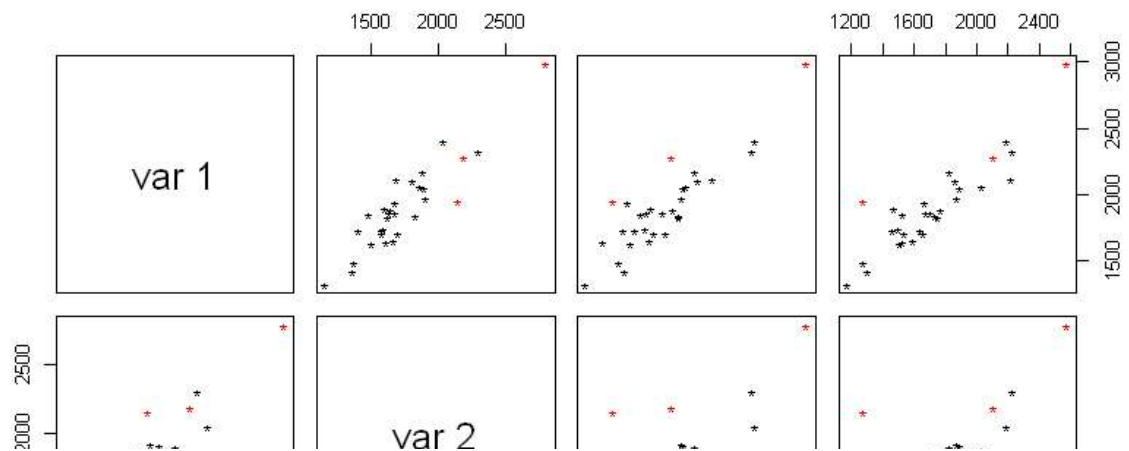
```
In [5]: stiffness = matrix(scan("stiffness.txt"), ncol=5, byrow=T)
x = stiffness[,1:4]
mu = apply(x, 2, mean)
sigma = cov(x)

n = nrow(x)
desvio = x - matrix(mu, nrow=nrow(x), ncol=ncol(x), byrow=T)
d2meu = diag(desvio %*% (solve(sigma) %*% t(desvio)))
# comando acima calcula D2
# R possui um comando proprio (e mais eficiente) para isto: mahalanobis
d2 = mahalanobis(x, mu, sigma)

# verificando que meu comando ineficiente calculou a mesma coisa
plot(d2, d2meu)
# identificando as anomalias
anomalias = d2 > qchisq(0.95,4)
x[anomalias,]
nanom = sum(anomalias)
# plotando e marcando em vermelho as anomalias
pairs(rbind(x, x[anomalias,]), pch="*", col=rep(c("black", "red"), c(n, nanom)))
```

```
2983 2794 2412 2581
1954 2149 1180 1281
2276 2189 1547 2111
```





Exercício 9

- Forneça uma estimativa para o vetor μ e para a matriz Σ e ρ .
- A partir da matriz de correlacao entre os pares de v.a.'s (e do plot de dispersao dos pontos), quais as variaveis que sao mais correlacionadas? E quais sao menos correlacionadas?
- Obtenha a distribuicao MARGINAL do sub-vetor $X^* = (X_1, X_2)$, o comprimento e largura da sepala.
- Obtenha a distribuicao CONDICIONAL do sub-vetor $X^* = (X_1, X_2)$ quando sao conhecidos os valores x_3 e x_4 das v.a.'s (X_3, X_4) . Obtenha esta distribuicao para dois valores genericos x_3 e x_4 . A seguir use dois valores especificos: $x_3 = 1.8$ e $x_4 = 0.6$, dois valores relativamente altos para estas variaveis. Compare $DP1 = \text{raiz}(V(X_1))$ com $\text{raiz}(V(X_1|X_3 = 1.8, X_4 = 0.6))$, o desvio padrao da variavel X_1 condicionada nos valores de X_3 e X_4 .
- Obtenha agora a distribuicao CONDICIONAL do sub-vetor $X^* = (X_1, X_2)$ quando e conhecido apenas o valor de X_3 .
- Obtenha tambem distribuicao CONDICIONAL do sub-vetor $X^* = (X_1, X_2)$ quando e conhecido apenas o valor de X_4 .
- Comparando as tres ultimas respostas que voce forneceu, qual das duas variaveis isoladamente, X_3 ou X_4 , diminui a incerteza acerca de X_2 mais fortemente? Isto e, se voce tivesse de escolher apenas uma delas, X_3 ou X_4 , qual voce iria preferir se seu objetivo fosse prever o valor de X_2 ?
- Considere a melhor preditora para X_2 que voce escolheu, dentre X_3 ou X_4 , na questao anterior. Digamos que tenha sido X_4 . Avalie quanto conhecer a outra variavel (neste caso, X_3) reduz ADICIONALMENTE a incerteza acerca de X_3 . Isto e, compare $V(X_2|X_4)$ com $V(X_2|X_3, X_4)$.

Resposta de todas as perguntas acima: (em ordem)

- Estimativas de μ e Σ :

```
In [6]: setosa <- iris[iris$Species == "setosa", 1:4]
pairs(setosa) # plots de pares das 4 variaveis
apply(setosa, 2, mean) # media aritmetica de cada variavel
cov(setosa) # estimativa da matriz de covariancia
cor(setosa) # estimativa da matriz de correlacao
round(cor(setosa),2) # valores arredondados em duas casas decimais
apply(setosa, 2, mean) # estimativa de mu
round(cov(setosa),3)
```

```
Sepal.Length  5.006
Sepal.Width   3.428
Petal.Length  1.462
Petal.Width   0.246
```


	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
Sepal.Length	0.12424898	0.099216327	0.016355102	0.010330612
Sepal.Width	0.09921633	0.143689796	0.011697959	0.009297959
Petal.Length	0.01635510	0.011697959	0.030159184	0.006069388
Petal.Width	0.01033061	0.009297959	0.006069388	0.011106122

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
Sepal.Length	1.0000000	0.7425467	0.2671758	0.2780984
Sepal.Width	0.7425467	1.0000000	0.1777000	0.2327520
Petal.Length	0.2671758	0.1777000	1.0000000	0.3316300
Petal.Width	0.2780984	0.2327520	0.3316300	1.0000000

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
Sepal.Length	1.00	0.74	0.27	0.28
Sepal.Width	0.74	1.00	0.18	0.23
Petal.Length	0.27	0.18	1.00	0.33
Petal.Width	0.28	0.23	0.33	1.00

```
Sepal.Length  5.006
Sepal.Width   3.428
Petal.Length  1.462
Petal.Width   0.246
```

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
Sepal.Length	0.124	0.099	0.016	0.010
Sepal.Width	0.099	0.144	0.012	0.009
Petal.Length	0.016	0.012	0.030	0.006
Petal.Width	0.010	0.009	0.006	0.011



• A partir da matriz de correlacao $\text{cor}(\text{setosa})$, o comprimento X_1 e a largura X_2 das sepalas são as variáveis mais correlacionadas: $\rho_{12} = 0.74$. A largura da sepala X_2 e o comprimento da petala X_3 são as menos correlacionadas, com $\rho_{23} = 0.18$.

• A distribuição do sub-vetor $X^* = (X_1, X_2)$, o comprimento e largura da sepala, vem diretamente dos elementos 1 e 2 de μ e do bloco da matriz Σ :

$$\mathbf{X}^* = \begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \sim N_2(\boldsymbol{\mu}[1:2], \boldsymbol{\Sigma}[1:2, 1:2]) = N_2\left(\begin{pmatrix} 5.006 \\ 3.428 \end{pmatrix}, \begin{bmatrix} 0.124 & 0.099 \\ 0.099 & 0.144 \end{bmatrix}\right)$$

• A distribuição condicional de $\mathbf{X}^* = (X_1, X_2)$ quando são conhecidos os valores (x_3, x_4) das v.a.'s (X_3, X_4) .

$$\begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \bigg| \begin{pmatrix} X_3 = x_3 \\ X_4 = x_4 \end{pmatrix} \sim N_2(\mathbf{m}, \mathbf{V})$$

onde, usando a notação das notas de aula

$$\begin{aligned} \mathbf{m} &= \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix} + \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} \begin{pmatrix} x_3 - \mu_3 \\ x_4 - \mu_4 \end{pmatrix} \\ &= \begin{pmatrix} 5.006 \\ 3.428 \end{pmatrix} + \begin{bmatrix} 0.016 & 0.010 \\ 0.012 & 0.009 \end{bmatrix} \begin{bmatrix} 0.030 & 0.006 \\ 0.006 & 0.011 \end{bmatrix}^{-1} \begin{pmatrix} x_3 - 1.462 \\ x_4 - 0.246 \end{pmatrix} \\ &= \begin{pmatrix} 5.006 \\ 3.428 \end{pmatrix} + \begin{bmatrix} 0.399 & 0.712 \\ 0.247 & 0.702 \end{bmatrix} \begin{pmatrix} x_3 - 1.462 \\ x_4 - 0.246 \end{pmatrix} \end{aligned}$$

Para $x_3 = 1.8$ e $x_4 = 0.6$ temos

$$\mathbf{m} = \begin{pmatrix} 5.006 \\ 3.428 \end{pmatrix} + \begin{pmatrix} 0.387 \\ 0.332 \end{pmatrix} = \begin{pmatrix} 5.393 \\ 3.760 \end{pmatrix}$$

Quanto a matriz de covariância \mathbf{V} para a distribuição condicional, temos ##

$$\begin{aligned} \mathbf{V} &= \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} \boldsymbol{\Sigma}_{21} \\ &= \begin{bmatrix} 0.124 & 0.099 \\ 0.099 & 0.144 \end{bmatrix} - \begin{bmatrix} 0.016 & 0.010 \\ 0.012 & 0.009 \end{bmatrix} \begin{bmatrix} 0.030 & 0.006 \\ 0.006 & 0.011 \end{bmatrix}^{-1} \begin{bmatrix} 0.016 & 0.012 \\ 0.010 & 0.009 \end{bmatrix} \\ &= \begin{bmatrix} 0.110 & 0.088 \\ 0.088 & 0.134 \end{bmatrix}. \end{aligned}$$

Temos $DP1 = \sqrt{V(X_1)} = \sqrt{0.124} = 0.352$ e $\sqrt{V(X_1|X_3 = 1.8, X_4 = 0.6)} = \sqrt{0.110} = 0.332$.

• Queremos a distribuição condicional do sub-vetor $\mathbf{X}^* = (X_1, X_2)$ quando é conhecido apenas o valor de $X_3 = 1.8$. Neste caso, é como se a variável X_4 não existisse: ela não está envolvida. Vamos obter a distribuição conjunta do vetor (X_1, X_2, X_3) e então usar a nossa fórmula de condicional da normal multivariada. Para obter a distribuição marginal de (X_1, X_2, X_3) , basta olhar $\boldsymbol{\mu}$ e $\boldsymbol{\Sigma}$ e ignorar as entradas associadas com X_4 . Temos

$$\begin{pmatrix} X_1 \\ X_2 \\ X_3 \end{pmatrix} \sim N_3\left(\begin{bmatrix} \mu_1 \\ \mu_2 \\ \mu_3 \end{bmatrix}, \begin{bmatrix} \sigma_{11} & \sigma_{12} & \sigma_{13} \\ \sigma_{21} & \sigma_{22} & \sigma_{23} \\ \sigma_{31} & \sigma_{32} & \sigma_{33} \end{bmatrix}\right) = N_3\left(\begin{bmatrix} 5.006 \\ 3.428 \\ 1.462 \end{bmatrix}, \begin{bmatrix} 0.124 & 0.099 & 0.016 \\ 0.099 & 0.144 & 0.012 \\ 0.016 & 0.012 & 0.030 \end{bmatrix}\right)$$

Dividindo este vetor em dois blocos, representados por letras em negrito e com indexação ligada aos blocos (e não as variáveis), podemos usar as fórmulas derivadas em sala de aula:

$$\begin{pmatrix} X_1 \\ X_2 \\ X_3 \end{pmatrix} \sim N_3 \left(\begin{bmatrix} \mu_1 \\ \mu_2 \\ \mu_3 \end{bmatrix}, \begin{bmatrix} \sigma_{11} & \sigma_{12} & \sigma_{13} \\ \sigma_{21} & \sigma_{22} & \sigma_{23} \\ \sigma_{31} & \sigma_{32} & \sigma_{33} \end{bmatrix} \right) \sim N_3 \left(\begin{bmatrix} \mathbf{m}_1 \\ \mathbf{m}_2 \end{bmatrix}, \begin{bmatrix} \mathbf{\Sigma}_{11} & \mathbf{\Sigma}_{12} \\ \mathbf{\Sigma}_{21} & \mathbf{\Sigma}_{22} \end{bmatrix} \right)$$

Temos

$$\begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \Big| X_3 = 1.8 \sim N_2(\mathbf{m}, \mathbf{V})$$

onde, usando a notação das notas de aula,

$$\begin{aligned} \mathbf{m} &= \mathbf{m}_1 + \mathbf{\Sigma}_{12} \mathbf{\Sigma}_{22}^{-1} (\mathbf{x}_2 - \mathbf{m}_2) \\ &= \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix} + \begin{bmatrix} \sigma_{13} \\ \sigma_{23} \end{bmatrix} [\sigma_{33}]^{-1} (1.8 - \mu_3) \\ &= \begin{pmatrix} 5.006 \\ 3.428 \end{pmatrix} + \begin{bmatrix} 0.016 \\ 0.012 \end{bmatrix} [0.030]^{-1} (1.8 - 1.462) \\ &= \begin{pmatrix} 5.006 \\ 3.428 \end{pmatrix} + \begin{bmatrix} 0.533 \\ 0.400 \end{bmatrix} (1.8 - 1.462) \\ &= \begin{pmatrix} 5.006 \\ 3.428 \end{pmatrix} + \begin{pmatrix} 0.180 \\ 0.135 \end{pmatrix} = \begin{pmatrix} 5.186 \\ 3.563 \end{pmatrix} \end{aligned}$$

e

$$\begin{aligned} \mathbf{V} &= \mathbf{\Sigma}_{11} - \mathbf{\Sigma}_{12} \mathbf{\Sigma}_{22}^{-1} \mathbf{\Sigma}_{21} \\ &= \begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{21} & \sigma_{22} \end{bmatrix} - \begin{bmatrix} \sigma_{13} \\ \sigma_{23} \end{bmatrix} [\sigma_{33}]^{-1} \begin{bmatrix} \sigma_{31} & \sigma_{32} \end{bmatrix} \\ &= \begin{bmatrix} 0.124 & 0.099 \\ 0.099 & 0.144 \end{bmatrix} - \begin{bmatrix} 0.016 \\ 0.012 \end{bmatrix} [0.030]^{-1} \begin{bmatrix} 0.016 & 0.012 \end{bmatrix} \\ &= \begin{bmatrix} 0.115 & 0.093 \\ 0.093 & 0.139 \end{bmatrix} \end{aligned}$$

• Temos $V(X_2|X_4 = 0.6) = 0.136 < 0.139 = V(X_2|X_3 = 1.8)$. Assim, saber que $X_4 = 0.6$ leva a uma menor incerteza acerca do valor de X_2 que aquela que resta quando $X_3 = 1.8$. Para prever X_2 , saber o valor de X_4 é melhor que saber o valor de X_3 . Observe que $0.139 = V(X_2|X_3 = 1.8) = V(X_2|X_3 = x)$ para todo x , bem como $0.136 = V(X_2|X_4 = 0.6) = V(X_2|X_4 = x)$ para todo x . Portanto, a conclusão sobre a maior redução da incerteza de X_2 alcançada pelo conhecimento do valor de X_3 , não depende dos valores específicos $x_3 = 1.8$ e $x_4 = 0.6$ usados no exercício. Teríamos a mesma conclusão com quaisquer dois valores para x_3 e x_4 pois as variâncias condicionais não variam com x_3 e x_4 .

• Entre X_3 e X_4 , a melhor preditora de X_2 é X_4 . Acrescentar o conhecimento sobre o valor de X_3 ao conhecimento de que $X_4 = 0.6$ reduz pouco a variabilidade (ou incerteza) acerca de X_2 :

$$0.134 = V(X_2|X_3 = 1.8, X_4 = 0.6) < V(X_2|X_4 = 0.6) = 0.136 < V(X_2) = 0.144$$

Exercício 10

10. Seja $\mathbf{X} = (X_1, X_2, X_3)'$ um vetor aleatório com distribuição normal multivariada com $\boldsymbol{\mu} = (\mu_1, \mu_2, \mu_3)' = [-1, 0, 2]'$ e

$$\boldsymbol{\Sigma} = \begin{bmatrix} 1 & -2 & 0 \\ -2 & 5 & 0 \\ 0 & 0 & 2 \end{bmatrix}$$

Seja \mathbf{b} um vetor k -dimensional e \mathbf{C} uma matriz $k \times 3$ formada por constantes. Uma das propriedades da normal multivariada é que a distribuição do vetor $\mathbf{b} + \mathbf{C}\mathbf{X}$ de dimensão k é normal com vetor de médias $\mathbf{b} + \mathbf{C}\boldsymbol{\mu}$ e matriz de $k \times k$ covariância $\mathbf{C}\boldsymbol{\Sigma}\mathbf{C}'$. Use esta propriedade para obter a distribuição das seguintes variáveis:

- Distribuição marginal de X_1 , de X_2 e de X_3 .
- Distribuição de um indicador composto pelas 3 variáveis: $T = 0.4X_1 + 0.3X_2 + 0.3X_3$.
- Distribuição de um indicador composto pelas 3 variáveis normalizadas: $T = 0.4(X_1 - 10)/2 + 0.3(X_2 - 20)/\sqrt{30} + 0.3(X_3 + 50)/\sqrt{94}$.
- Distribuição conjunta de $(X_1 - X_2, 4X_1 + 2X_2 - X_3)$.
- Distribuição conjunta de $(X_1, aX_1 + bX_2 + cX_3)$, onde a, b, c são constantes reais. Em particular, encontre a covariância entre X_1 e o indicador $Y = aX_1 + bX_2 + cX_3$ formado pela combinação linear de X_1, X_2 e X_3 .

Exercício 3 - Capítulo 6

3. Consideramos um modelo probabilístico para um problema de diagnóstico de falhas. Uma variável binária C representa a integridade de uma unidade de disco: $C = 0$ significa que esta operando normalmente e $C = 1$ significa esta em estado de falha. Quando a unidade está em funcionamento, monitora-se continuamente usando um temperatura e sensor de choque, e registra duas características binárias, X e Y . Temos $X = 1$ se o drive foi sujeito a choque (por exemplo, caiu), e $X = 0$, caso contrário. Temos $Y = 1$ se a unidade a temperatura já foi acima

de 700 e $Y = 0$, caso contrario. A tabela abaixo define a funcao de massa de probabilidade conjunta dessas tres variaveis aleatorias:

x	y	c	$p_{X,Y,C}(x, y, c)$
0	0	0	0.10
0	1	0	0.20
1	0	0	0.20
1	1	0	0.10
0	0	1	0.00
0	1	1	0.10
1	0	1	0.05
1	1	1	0.25

Forneça o valor numérico das probabilidades abaixo:

- Qual e a probabilidade $P(C = 1)$?

Solução: $P(C = 1) = 0.0 + 0.1 + 0.5 + 0.25 = 0.85$

- Qual e a probabilidade $P(C = 0|X = 1, Y = 0)$?

Solução: $P(C = 0|X = 1, Y = 0) = 0.2$

- Qual e a probabilidade $P(X = 0, Y = 0)$?

Solução: $P(X = 0, Y = 0) = 0.1$

- Qual e a probabilidade $P(C = 0|X = 0)$?

Solução: $P(C = 0|X = 0) = 0.3$

- São X e Y independentes? Justifique sua resposta.

Solução: $0.4 \cdot 0.35 \neq 0.1$ para o primeiro valor da tabela, e como isso difere concluímos que X e Y não são independentes.

In []:

In []:

In []:

In []: